Enjeux communicationnels des données

CM1 - Présentation du cours et introduction

TE54IC – L3 info-com, Université Paul Valéry Montpellier 3
S. Labelle, L. Delias

Présentation du cours

⚠ Voir le plan de cours sur Moodle ⚠
Code TE54IC

- Objectifs
- Intervenant-e-s
- Calendrier
- Evaluation

Calendrier et horaires

Répartition des heures

18h CM – 18h TD (9 séances de 2h chacune)

Coefficients

50% pour le CM, 50% pour le TD

Planning

Voir l'emploi du temps et de plan de cours !

Intervenant-es

CM : Lucie Delias lucie.delias@univ-montp3.fr

TD :

- Lucie Delias : lucie.delias@univ-montp3.fr
- Florentin Groh : florentin.groh@univ-montp3.fr

Objectifs du CM

Comprendre les enjeux éthiques et communicationnels des **technologies numériques contemporaines basés sur des systèmes de calcul de données : les algorithmes et les outils d'intelligence artificielle**, qui prennent une place de plus en plus importante dans la vie sociale mais aussi dans les métiers de la communication.

- Comprendre comment ces technologies fonctionnent à un niveau technique, politique et stratégique
- Comprendre en quoi ces technologies transforment notre environnement et nos pratiques tout en mettant à distance les discours idéologiques des acteurs du secteur de la tech
- Développer un regard critique, et *in fine* des pratiques plus éthiques, sur les outils d'IA

Semaine	Date	Thème
Semaine 1	Jeudi 11 septembre	Présentation générale du cours et introduction : données, algorithmes et intelligence artificielle
Semaine 2	Jeudi 18 septembre	Données publiques, données pour agir
Semaine 3	Jeudi 25 septembre	Histoire scientifique, sociale et culturelle des outils d'intelligence artificielle
Semaine 4	Jeudi 2 octobre	Données, biais algorithmiques et diversité
Semaine 5	Jeudi 9 octobre	Enjeux sociopolitiques de l'IA : politiques publiques et régulation
Semaine 6	Jeudi 16 octobre	Enjeux socioéconomiques de l'IA
Semaine 7	Jeudi 23 octobre	Enjeux environnementaux de l'IA
Vacances de la Toussaint		
Semaine 8	Jeudi 6 novembre	Les mondes professionnels face à l'IA
Semaine 9	Jeudi 13 novembre	Cours de révision
Semaine 10	Jeudi 20 novembre	**Partiel : Amphi 2, de 13h15 à 15h15**

Evaluation finale du CM

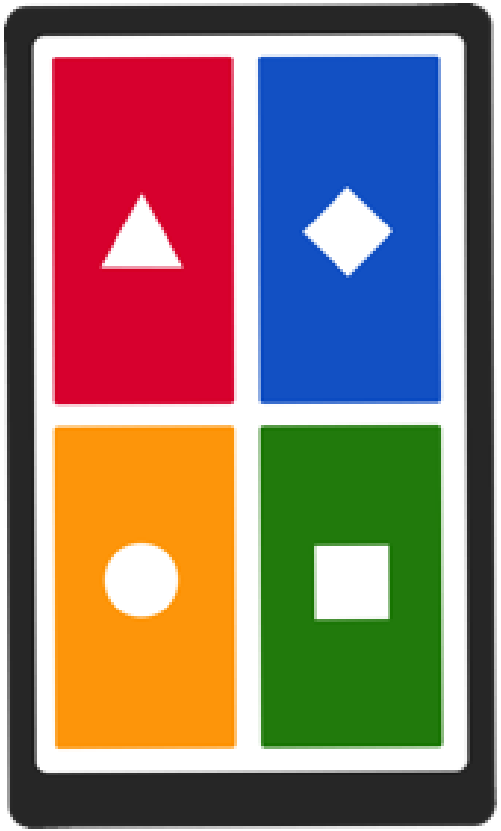
Date

- Jeudi 20 novembre de 13h15 à 15h15

Modalités

- Un devoir sur table de 2h composé de questions de cours et d'un sujet de réflexion
- Préparation à l'examen pendant la séance de révision du 13 novembre

Introduction



Testez vos connaissances sur les données, les algorithmes et les outils d’IA

🍽 Au menu aujourd'hui 🍽

I. Les systèmes de calculs : algorithmes et outils d'intelligence artificielle

1. Les algorithmes
- Origine des algorithmes
- Fonctionnement des algorithmes
- Les différents types d'algorithmes dans notre vie quotidienne

2. Les outils d'intelligence artificielle
- Définition de l' « intelligence artificielle »
- Fonctionnement des outils d'IA
- Une progression très rapide de ces outils

II. Données et datafication

- La datatafication ou « mise en données » de la société
- De quels types de données se nourrissent les systèmes de calcul ?

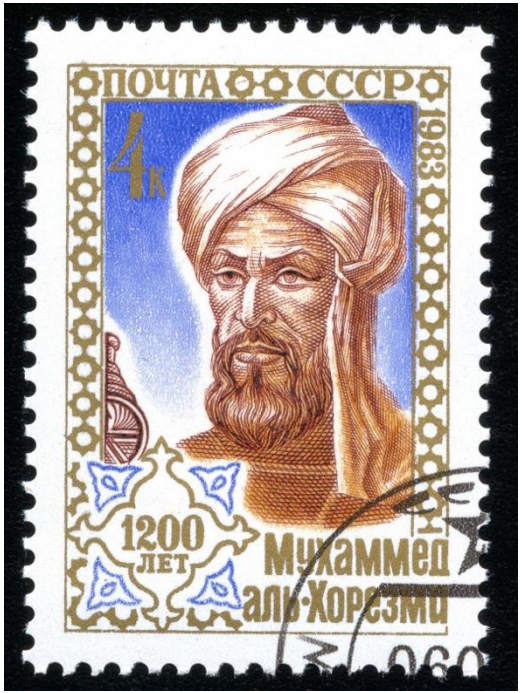
Les systèmes de calculs : algos et IA

1. Les algorithmes

Quels sont les services que nous utilisons au quotidien qui fonctionnent grâce à des algorithmes ?

L'origine des algorithmes

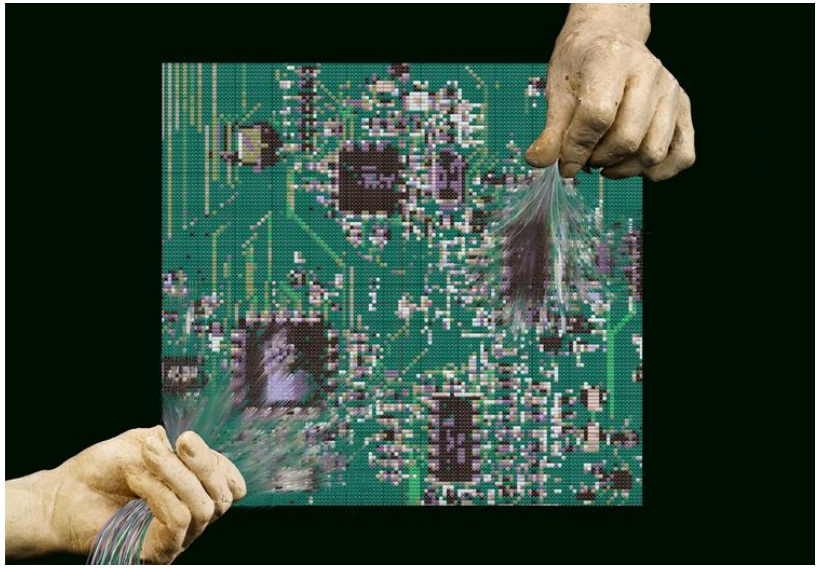
- Un principe ancien issu des mathématiques…
  - voir Abu Abdullah Muhammad ibn Musa al-Khwarizmi, mathématicien perse du IX° siècle, le « père de l'algèbre »
- … qui désigne une manière de procéder systématiquement pour arriver à un résultat
  - *Faire un produit en croix, poser une addition ou une soustraction…*
- Application contemporaine dans le domaine de l'informatique (= *traitement de l'information de manière automatique*), où un algorithme désigne un programme destiné aux machines pour traiter automatiquement des données et produire des résultats



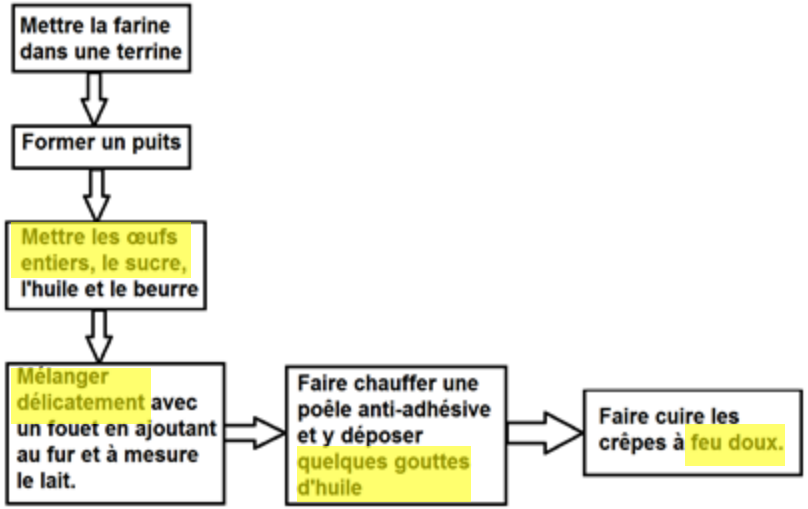
Fonctionnement d'un algorithme

1. Le concepteur ou la conceptrice détermine une série d'instructions à suivre dans un certain ordre pour effectuer une tâche de manière automatique (c'est-à-dire sans avoir besoin de comprendre ou de réfléchir)

2. La liste d'instruction est ensuite traduite dans un langage informatique compréhensible pour une machine = on obtient un programme algorithmique



L'exemple de la recette de cuisine



Recette pâte à crêpes

6 juillet 2011 dans Recettes

Pour environ 15 crêpes

- 250g de farine
- 4 oeufs
- 1/2 litre de lait
- 1 CS de sucre vanillé
- 1 pincée de sel
- 50g de beurre
- (facultatif : 1 CS de rhum, fleur d'oranger)

Préparation

Mettre la farine dans une terrine et former un puits. Mettre les œufs entiers, le sucre, l'huile et le beurre.

Mélanger délicatement avec un fouet en ajoutant au fur et à mesure le lait. La pâte ainsi obtenue doit avoir une consistance d'un liquide légèrement épais.

Faire chauffer une poêle anti-adhésive et y déposer quelques gouttes d'huile. Faire cuire les crêpes à feu doux.

Comparaison

🍕 **Une recette de cuisine** 🍕		💻 **Un algorithme informatique** 💻
Des ingrédients	→	Des données
Une suite d'étapes	→	Des séquences d'instructions
Des indications peu précises (savoirs informels et expérientiels)	→	Un langage informatique et formalisé lisible par une machine
Un plat	→	Le résultat du calcul

Les différents types d'algorithmes

Algorithmes de tri

Un algorithme de tri permet **de placer les éléments d'une liste dans un certain ordre** ; il peut permettre d'effectuer des classements (*ex : le Page Rank de Google Search*)

Algorithmes d'appariement

Un algorithme d'appariement permet **d'associer des éléments entre eux** en fonction de critères de correspondance (*ex : ParcoursSup, Uber…*)

Algorithmes de recommandation

Un algorithme de recommandation est une forme spécifique de filtrage de l'information visant à **présenter les contenus qui sont susceptibles d'intéresser l'utilisateur** (*ex : Netflix, TikTok…*)

Algorithmes de chiffrement

Un algorithme de chiffrement permet, à partir d'une clé, **d'encoder un message pour le rendre incompréhensible**, sauf pour la personne qui dispose de la clé pour le décoder (*ex : messageries cryptées comme Signal, Telegram…*)

2. Les outils d'intelligence artificielles

À ce stade, quel est selon vous le lien entre algorithmes et intelligence artificielle ?

Qu'est-ce que l'« intelligence artificielle » ?

L'intelligence artificielle est **un procédé logique et automatisé** reposant généralement sur **un algorithme** et en mesure de **réaliser des tâches bien définies**. Pour le Parlement européen, constitue une intelligence artificielle **tout outil utilisé par une machine afin de « reproduire des comportements attribués aux humains, tels que le raisonnement, la planification et la créativité »**

(Site de la CNIL, https://www.cnil.fr/fr/intelligence-artificielle/intelligence-artificielle-de-quoi-parle-t-on)



Fonctionnement des outils d'IA

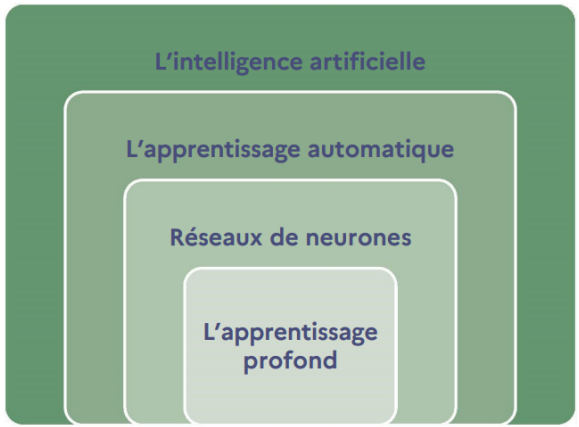


Vidéo
« **Du machine learning et des données. Découvrir #2** »
Chaine YouTube Inria-Médiation scientifique

https://www.youtube.com/watch?v=bLvabh0asQU

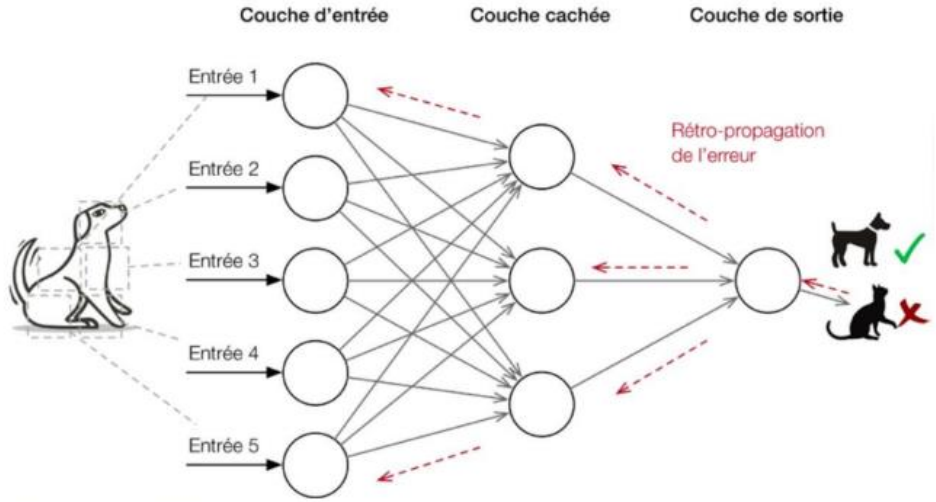
IA, machine learning et deep learning

IA, apprentissage automatique, réseau de neurones et apprentissage profond



(UNESCO, 2021)

Fonctionnement d'un réseau de neurones simple



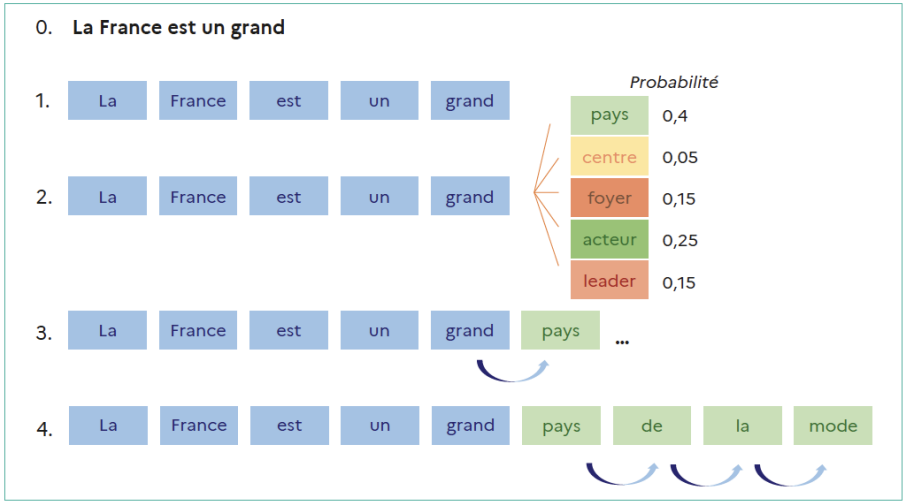
(Cardon et al., 2018)

Source : Intelligence artificielle et éducation : apports de la recherche et enjeux pour les politiques publiques (DNE, 04-2023)

Le fonctionnement de outils d'IAG textuelles

Exemple de ChatGPT ou DeepSeek

- LLM : Large Langage Model
- Un modèle statistique probabiliste
- Traitement du langage naturel



Rapport « IA : notre ambition pour la France », Commission de l'intelligence artificielle, 2024

Analyse du texte d'entrée

Contextualisation

Génération de la réponse et du texte de sortie



Requête
Prompting

La **requête** est un texte composé de mots, de phrases et de signes de ponctuation. Une personne l'écrit dans l'intention d'obtenir une réponse à une question, une instruction ou une demande.

Segmentation

La **segmentation** prépare le texte en le décomposant en mots, en parties de mots ou en caractères typographiques.

Analyse lexicale
Tokenization

L'**analyse lexicale** associe un symbole (*token*) à chaque mot, partie de mot ou caractère typographique.

Plongement lexical
Embeddings

Le **plongement lexical** convertit les symboles de la requête en vecteurs qui possèdent chacun un millier d'éléments. Le modèle peut mesurer la distance entre deux vecteurs: cette distance représente la proximité sémantique entre deux vecteurs.

Réseau de neurones autoattentif
Transformer

Le **réseau de neurones auto-attentif** (*transformer*) établit des relations entre les vecteurs en entrée et les vecteurs du modèle pré-entraîné. Cela lui permet de tenir compte du contexte. Le réseau contient 175 milliards de relations.

Génération symbole par symbole
Token-by-token

Le système **génère le vecteur le plus probable** étant donnée la suite de vecteurs fournie en entrée.

Génération de la réponse

La **réponse** consiste en une suite de symboles que produit le réseau de neurones autoattentif.

Formatage

Le système **formate** la réponse (une suite de symboles) en utilisant des caractères typographiques.

Réponse en langage naturel

Le système révise et corrige le texte de sortie et finalement l'affiche sur l'**interface conversationnelle**.

3IT Institut interdisciplinaire d'innovation technologique UdS

UdS Université de Sherbrooke

Dany Baillargeon, François Thibeault, Alexandra Lez et Céline Verchère. 2023. *Comment fonctionne ChatGPT de la requête à la réponse*. Institut interdisciplinaire d'innovation technologique et Université de Sherbrooke. En ligne https://miro.com/app/board/uXjVMAp7-zg=/?share_link_id=851063995468

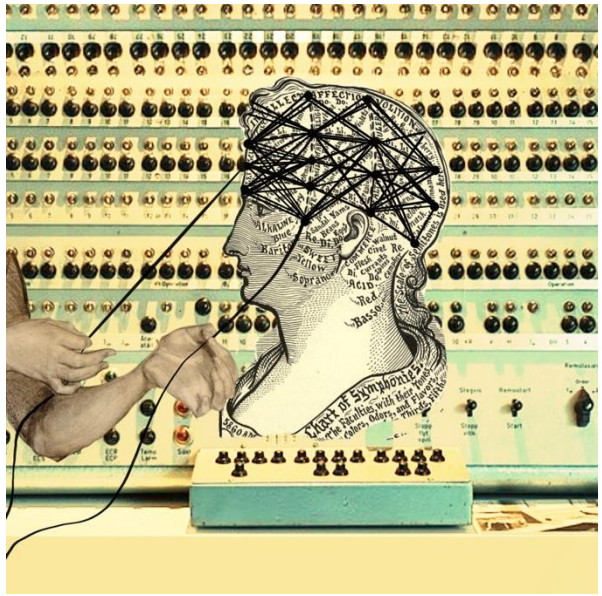
🥳 Pause ? 🎉

« IA », au pluriel ou au singulier ?

- Au singulier, fait référence à **un domaine de recherche** :

  « L'intelligence artificielle (IA) est une discipline jeune d'une soixante d'années, qui est un ensemble de sciences, théories et techniques (notamment logique mathématique, statistiques, probabilités, neurobiologie computationnelle, informatique) qui ambitionne d'imiter les capacités cognitives d'un être humain » (Conseil de l'Europe, « Histoire de l'IA »)

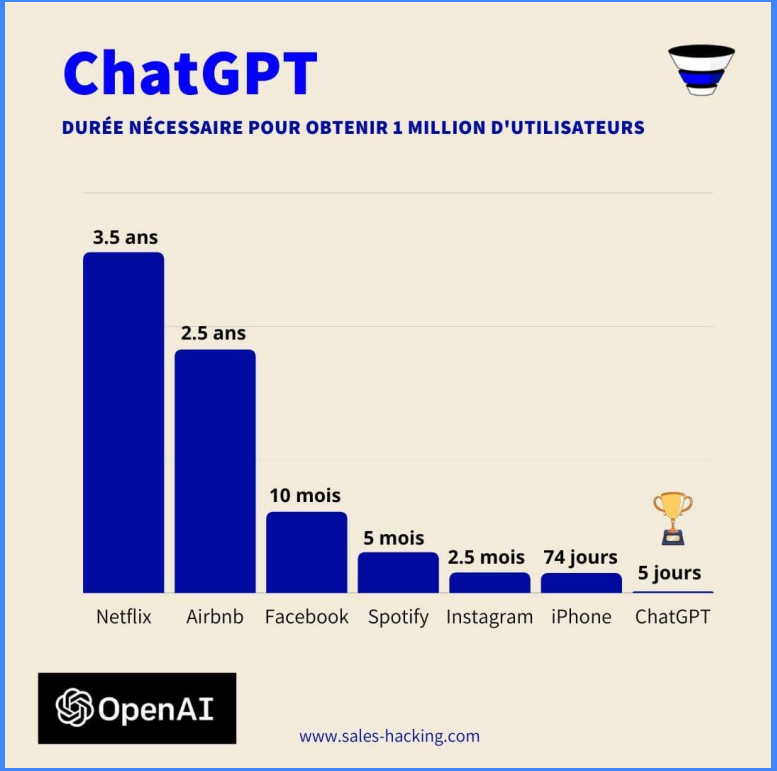
- Au pluriel, désigne **un grand nombre d'outils**, au fonctionnement et aux objectifs différents, basés sur des techniques issues de l'intelligence artificielle
  - Génération de contenus (IAG)
  - Reconnaissance d'images ou de sons
  - Modélisation scientifique (Ex : Alpha de Météo France, AI de détection des cancers en médecine…)
  - Robotique (véhicules autonomes)



Turning Threads of Cognition by Hanna Barakat & Cambridge Diversity Fund

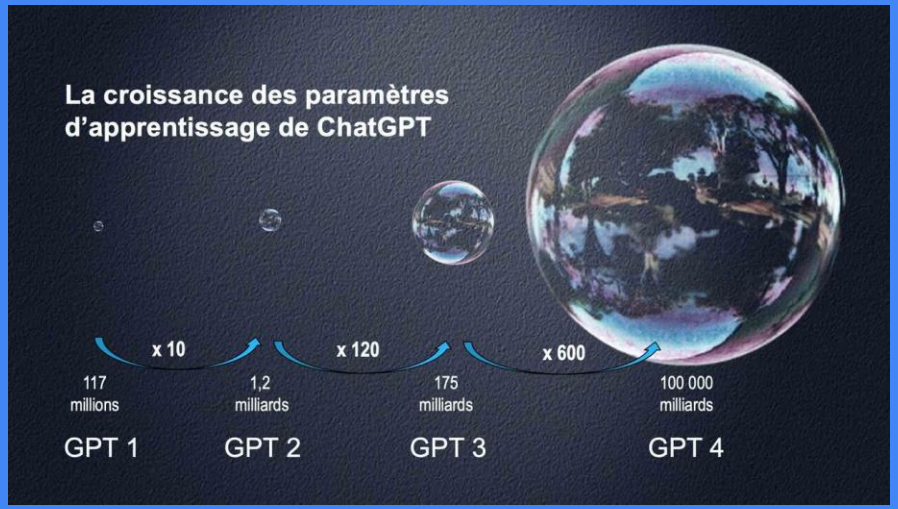
Une progression très rapide

En termes de nombre d'utilisateurs



Une progression très rapide

En termes de performance des modèles et de résultats



Pierre Paperon

Une progression très rapide

En termes de performance des modèles et de résultats

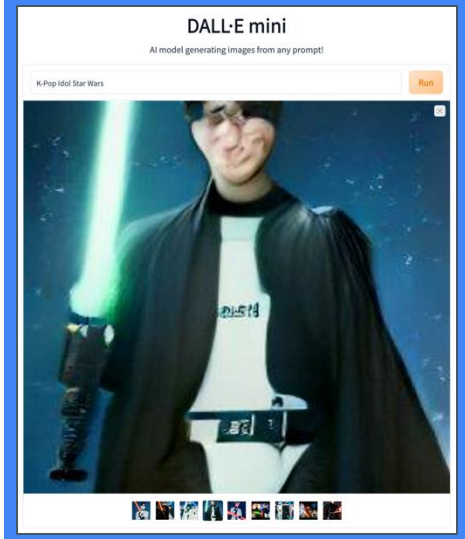
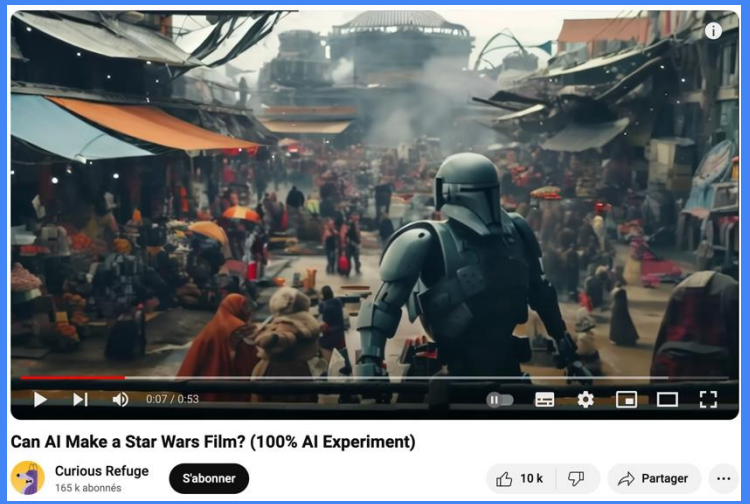


Image réalisée avec DALL-E mini, été 2022

Vidéo réalisée avec Midjourney, 2024

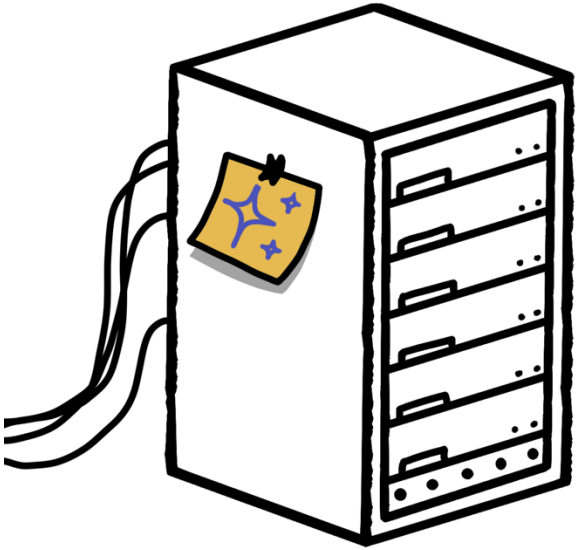


Données et datafication

Pourquoi ce « bond en avant » de l'IA ?

Le développement exponentiel des outils d'IA ces dernières années est lié :

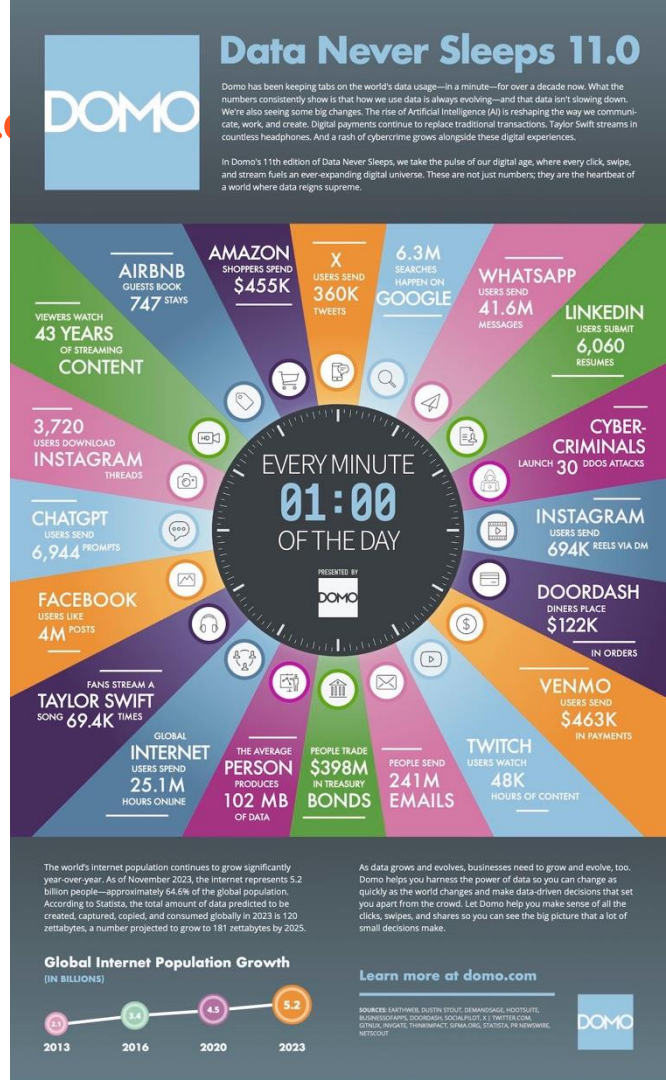
- À des **technologies informatiques** toujours plus puissantes (ex : TPU, GPU)
- À **l'explosion du nombre de données** disponibles pour entrainer les modèles
  - Données produites grâce à des capteurs, par divers acteurs (télescopes, capteurs de CO2, vidéo surveillance…)
  - Données liées aux activités numériques des usagers (internet des objets, réseaux sociaux, navigation web…)



Combien de données sont produite chaque minute dans le monde ?

Rapport annuel « Data Never Sleeps » de Domo

« Le Big Data n'est pas seulement un concept abstrait utilisé pour inspirer et mystifier la communauté de la tech ; c'est le résultat d'une avalanche d'activités numériques qui pulsent à travers les câbles et les ondes dans le monde entier. Ces données sont créées chaque minute de la journée par des activités en ligne anodines que beaucoup d'entre nous remarquent à peine. Mais chaque fois que nous naviguons sur un site web, que nous partageons un statut ou que nous téléchargeons une photo, nous laissons des traces numériques qui ne cessent de grossir la masse imposante des big data. » (Data Never Sleeps, 2013)



Datafication ou « mise en données » de la société

« **La datafication fait référence au processus par lequel les sujets, les objets et les pratiques sont transformés en données numériques**. Associée à l'essor des technologies numériques, de la numérisation et du big data, de nombreux chercheurs affirment que la datafication s'intensifie à mesure que de plus en plus de dimensions de la vie sociale se déploient dans les espaces numériques. La datafication restitue une gamme diversifiée d'informations sous forme de données quantifiables et lisibles par machine à des fins d'agrégation et d'analyse.
La datafication est également utilisée comme terme pour décrire une logique qui considère les choses dans le monde comme des sources de données à « exploiter » pour des corrélations ou à vendre, et à partir desquelles des informations peuvent être obtenues sur le comportement humain et les problèmes sociaux. »

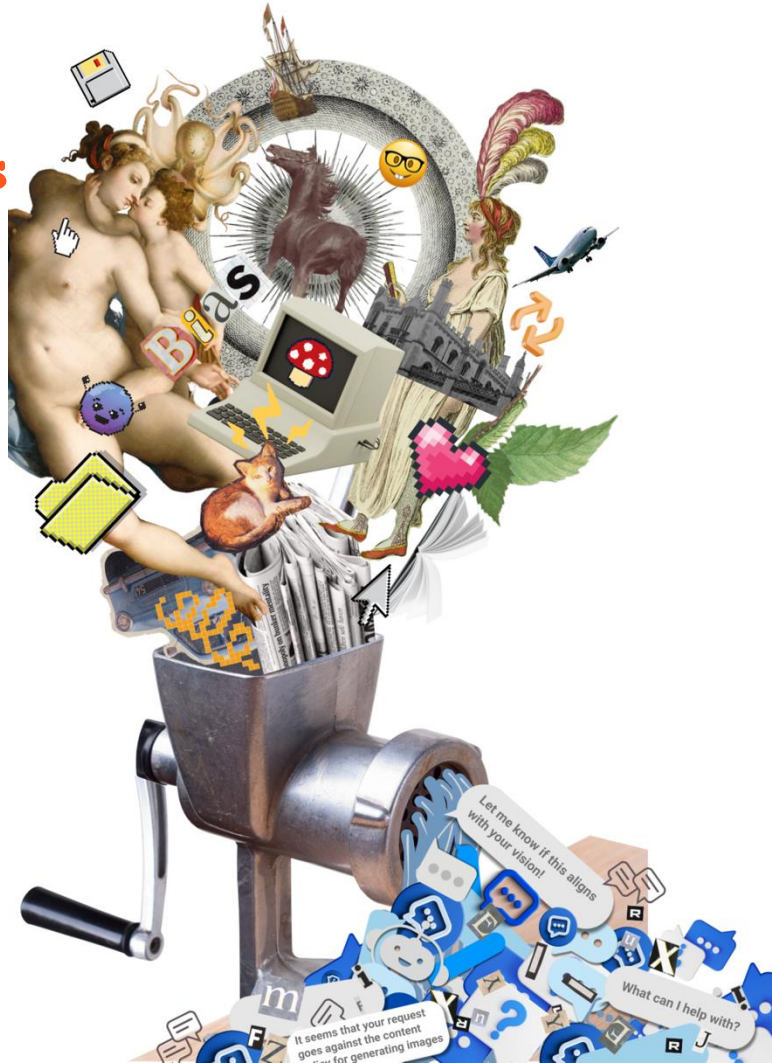
(C. Southerton, *Encyclopedia of big data*, 2020)

De quelles données se « nourrissent » les systèmes de calcul ?

Deux grandes « familles » de données sont utilisées pour entrainer les modèles d'IA contemporains

1. Les données produites par les usagers des outils numériques

2. Les données (re)produites par les concepteurs des outils d'IA



1. Les données produites par les usagers des outils numériques

- **Les données aspirées (*web-scraping*) de sources variées sur le Web, de 4Chan à Wikipédia**
  - Biais occidentaux
  - Biais idéologiques
- **Les données d'usages des réseaux sociaux**
  - Extension de l'exploitation du « travail gratuit des usagers » (*digital labor*)
- **Les données en ligne produites par des professionnels**
  - Le cas des médias et des journalistes
  - Ex de WeTransfer



CNIL. PROTÉGER les données personnelles ACCOMPAGNER l'innovation PRÉSERVER les libertés individuelles

IA : Meta entraînera ses systèmes d'IA avec les données des utilisateurs européens dès fin mai 2025

27 mai 2025

*Dès fin mai, Meta utilisera les données des utilisateurs européens de Facebook et Instagram pour entraîner ses systèmes d'**intelligence artificielle**. Les utilisateurs seront prochainement informés, notamment de la possibilité de s'opposer dès maintenant au traitement de leurs données à ces fins.*

2. Les données produites par les concepteurs des outils d'IA

- **Les bases de données à destination des data scientists**
  - Une question de quantité mais aussi de qualité des données
  - Ex. des outils de reconnaissance faciale moins performants sur les visages féminins et non blancs (Joy Buoamwini, 2017)

- **Les données synthétiques**
  - Pour les cas où les données sont confidentielles (sécurité, santé…)
  - Vers une « autophagie » des outils d'IAG et un potentiel effondrement des modèles ?



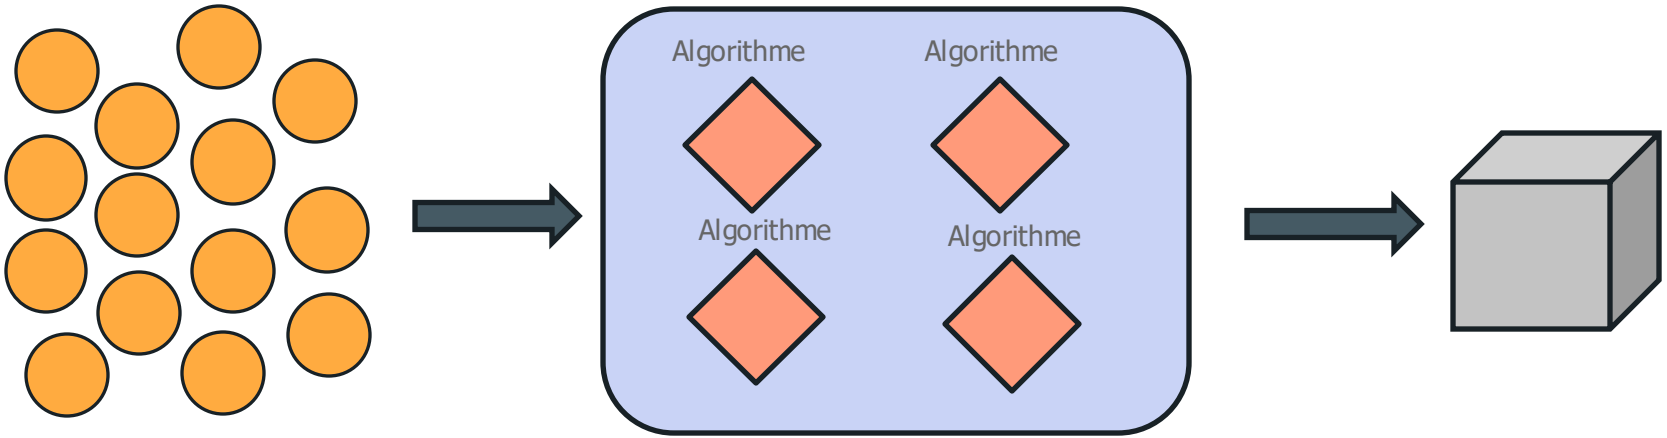


Tiré de "ON THE STABILITY OF ITERATIVE RETRAINING OF GENERATIVE MODELS ON THEIR OWN DATA" Publié lors de la conférence ICLR 2024

Figure 1 : Échantillons générés par l'EDM entraîné sur l'ensemble de données FFHQ. Le réentraînement itératif du modèle exclusivement sur ses propres données générées entraîne une dégradation de l'image (rangée supérieure). En revanche, le réentraînement sur un mélange de données à moitié réelles et à moitié synthétiques (au milieu) donne une qualité similaire au réentraînement sur des données réelles (en bas).

INRIA, « Vers un risque d'effondrement des IA génératives ? », 20 février 2025
https://www.inria.fr/fr/risque-effondrement-collapse-ia-generatives#:~:text=En%20effet%2C%20%C3%A0%20force%20de,qu'en%20richesse%20de%20contenu.

Pour résumer : le lien entre données, algorithmes et intelligence artificielle



Données d'entrainement (issues du web, des réseaux sociaux, de bases de données professionnelles…)

Système d'intelligence artificielle

Résultats qui imitent les capacités cognitives humaines