Enjeux communicationnels des données

CM3 – Biais algorithmiques

TE54IC – L3 info-com, Université Paul Valéry Montpellier 3
S. Labelle, L. Delias

🍽 Au menu aujourd'hui 🍽

I. Retour sur la séance 2
- Rappels du cours
- La question de l'intelligence

II. Les biais algorithmiques
- Les biais dans la reconnaissance faciale
- Les biais dans la génération d'image
- Définition des biais algorithmiques

III. Les 3 types de biais algorithmiques
- Les biais de sélection, d'imitation, et inhérents au modèle
- Les conséquences sur les populations vulnérables

IV. IA et pouvoir
- La production des technologies, un enjeu de pouvoir
- Les 3 niveaux de définition des algorithmes

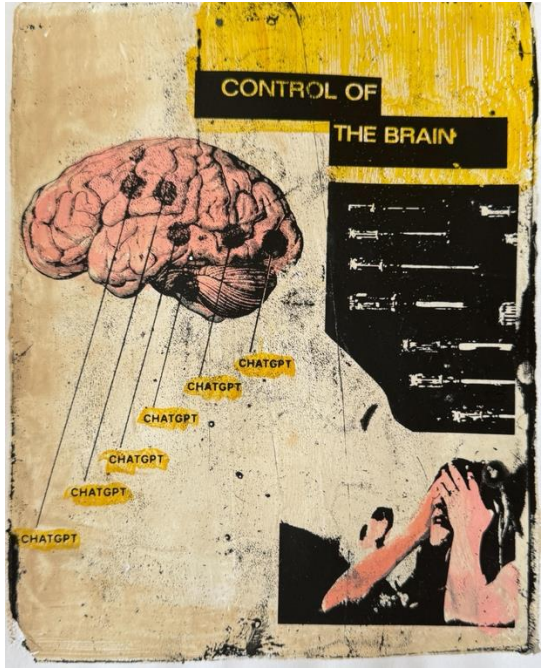
Rappels CM2 – Histoire culturelle et scientifique de l'IA

- L'IA : une technologie qui fait l'objet de beaucoup de **représentations dans la culture populaire**, alimentant des fantasmes de machines autonomes dotées de conscience
- L'IA est avant tout un champ de recherche, avec **d'une histoire complexe et non linéaire** : IA connexionniste, IA symbolique, hiver de l'IA
- La **revanche de l'IA connexionniste** : la domination actuelle des IA basées sur la statistique probabiliste, les réseaux de neurones et le deep learning (exemple de GPT de OpenAI)

La question de l’intelligence

Les machines sont-elles « intelligentes » ?

- **Une définition de l'intelligence biologique en évolution permanente**
  - La naissance parallèle des sciences cognitives et de l'IA
  - Être intelligent, est-ce être capable de gagner aux échecs ?
- **Des performances inférieures à celles du cerveau ?**
  - Combien faut-il d'images de chats à un enfant de deux ans pour en reconnaitre un ?
  - Un besoin en ressources énorme
  - Des tâches très spécialisées et basées sur des probabilités statistiques
- **Les spécificités de l'esprit humain**
  - Imitation de certaines capacités cognitives, mais pas l'intelligence globale (complémentarité des aspects émotionnels et logiques)
  - La question de la créativité
  - La question de l'autonomie



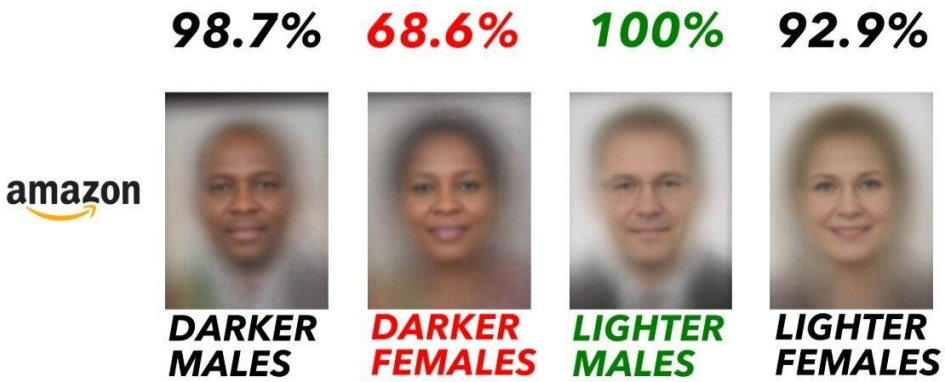
Brain Control by Bart Fish & Power Tools of AI

Les biais algorithmiques

Les biais dans la reconnaissance d'images

Documentaire ***Coded Bias***
Shalini Kantayya, 2020, USA





Performance du logiciel de reconnaissance faciale d'Amazon en fonction du genre et de la couleur de peau



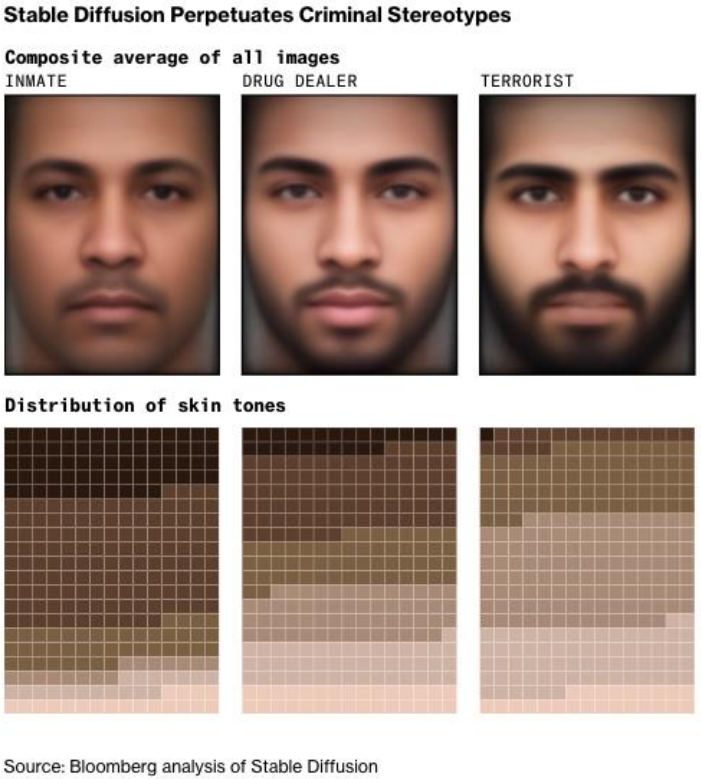
Joy Buolamwini & Deborah Raji

Les biais dans la génération d'images

Bloomberg, « Humans are biaised. Generative IA is even worse », juin 2023

- Méthode : génération et analyse de 5000+ images sur les catégories d'emploi et liées à la criminalité
- Biais de genre : 3% des juges générés sont des femmes vs 34% de femmes parmi les juges dans la réalité
- Biais de « race » : 70% des équipiers de fast-food générés ont la peau foncée vs 70% d'équipiers blancs dans la réalité

« À chaque étape du processus où un être humain peut faire preuve de partialité, l'IA peut également faire preuve de partialité. Et la différence est que la technologie légitime la partialité en la rendant plus objective, alors que ce n'est absolument pas le cas. » (N. Napolitano, Center for Policing Equity).



Qu'est-ce qu'un biais algorithmique ?

Définition

« On parle de biais algorithmiques **lorsqu'un algorithme d'intelligence artificielle pénalise une partie de la population**, soit parce qu'il reproduit une discrimination préexistante, soit parce que certaines populations sont sous-représentées dans les données d'apprentissage. » (Data for Good, Les grands défis de l'IA générative, 2023).

Critères de discriminations dans la loi de 2008

L'origine, le sexe, la situation de famille, la grossesse, l'apparence physique, la précarité, le patronyme, le lieu de résidence, l'état de santé, la perte d'autonomie, le handicap, les caractéristiques génétiques, les mœurs, l'orientation sexuelle, l'identité de genre, l'âge, les opinions politiques, les activités syndicales, la capacité à s'exprimer dans une langue autre que le français, l'appartenance – ou non – à une ethnie, une nation, une prétendue race ou une religion déterminée.

Les 3 types de biais algorithmiques

3 types de biais algorithmiques

- Les biais de sélection
- Les biais d’imitation
- Les biais inhérents au modèle

Les biais de sélection

Quand les biais proviennent de données incomplètes ou biaisées

Le cas de la provenance des données d'entrainement utilisées par OpenAI

Une stratégie basée sur des **« scale up laws »** qui pousse à privilégier la quantité des données sur leur qualité

- GPT2 : création du jeu de données WebText
- GPT3 : Reddit, Wikipédia en anglais, Books2, Common Crawl filtré
- GTP4 : Common Crawl non filtré, GitHub, et une multitude de contenus web

Problèmes :

- Multiplication des contenus discriminants et violents (« hate scaling laws », Birhane et al., 2023)
- Seulement une petite partie de la culture mondiale est représentée sur le web
- La zone grise légale de l'extraction des contenus en ligne

Les biais d'imitation

Quand les données sont le reflet d'une société déjà profondément inégalitaire

Le manque de données sur certaines populations

- Le syndrome de Yentl (C. Criado Perez, 2019) : l'exemple des maladies et accidents cardio-vasculaires

Les représentations des personnes minorisées dans l'espace public

- La proportion des individus minoritaires dans les contenus audiovisuels (E. Macé, 2006)
- Histoire de l'art



Les biais inhérents au modèle

Quand la manière dont les algorithmes sont programmés renforce le problème

Exemple de Tay

- ChatBot de Microsoft, lancé sur Twitter en 2016
- Paramètres d'adaptation à l'environnement mal calibrés

Les stratégies pour modérer les algorithmes

- Discrimination positive (Dall·e)
- Alignement des modèles (*fine-tunning*) grâce à l'entrainement humain des algorithmes (*Reinforcement Learning From Human Feedback*)





Pause !



Les conséquences pour les populations vulnérables

Reconnaissance faciale et corporelle

Un enjeu pour la sécurité des personnes minorisées

- Reconnaissance faciale par les forces de l'ordre : le risque d'erreurs judiciaires
- La détection des piétons par les algorithmes des véhicules autonomes
- Les données biométriques

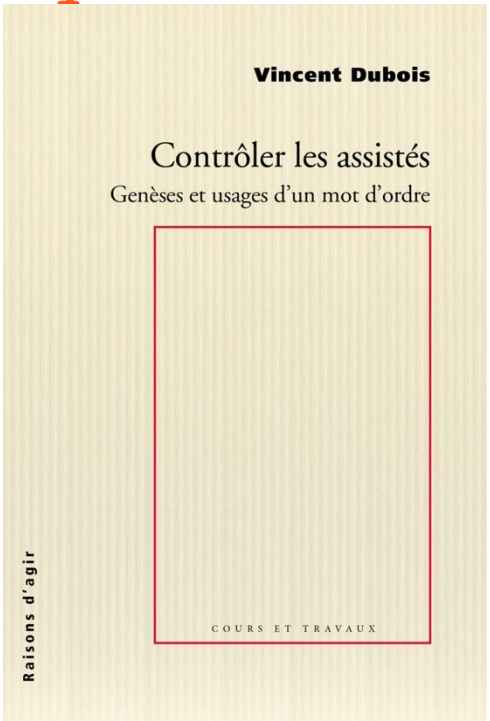


Porcha Woordruff, jeune mère et enceinte de 8 mois à l'époque, accusée à tort en 2023 de vol de voiture en raison d'une erreur du logiciel de reconnaissance faciale de la police de Détroit

Prédictions automatisées et prise de décision dans l'action publique

La (re)reproduction automatisée des inégalités

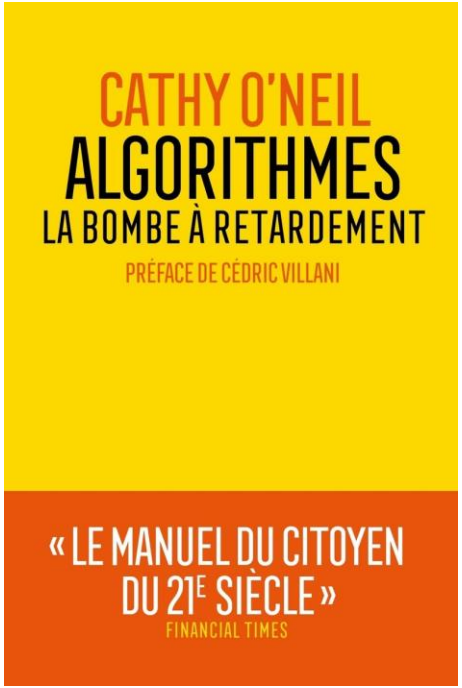
- Le cas de l'action policière (O'Neil, 2018)
- Le cas des services sociaux (Eubanks, 2018)
- Le cas de la Caisse d'Allocations Familiales en France (Dubois, 2021)



Une boucle de rétroaction négative

- Production d'une boucle de rétroaction négative des inégalités ; prophétie autoréalisatrice (C. O'Neil, 2018)

- « Les algorithmes prédictifs font l'hypothèse que notre futur sera une reproduction de notre passé » (D. Cardon, 2015)



IA et pouvoir

Le visage des « patrons de la tech »



Peter Thiel, PayPal



Jeff Bezos, Amazon



Larry Page, Google



Elon Musk, Tesla



Sam Altman, OpenAI



Dario Amodei, Anthropic



Jensen Huang, Nvidia



Mark Zuckerberg, Meta

La production des technologies, un enjeu de pouvoir

- Dans le monde de la tech, **les décisionnaires et les concepteurs sont majoritairement issus d'un groupe social homogène**
  - En France, seulement 25% des femmes diplômées de l'enseignement supérieur ont un diplôme dans la filière numérique et 13% travaillent dans le numérique.
  - Dans la Silicon Valley, 7% d'entrepreneuses et 13% de femmes dans les postes de management
- **« I-methodology » ou « méthodologie du je »** (Madeleine Akrich)

  Lorsque les concepteurs des objets techniques imaginent que leur vécu, leur ressenti et leurs préférences sont représentatives de celles de l'ensemble des usagers, et construisent des outils correspondant à leurs propres valeurs et usages



Mira Murati, ex directrice technique chez OpenAI et fondatrice de Thinking Machines Lab