TD 5 – Algorithme des k-means

Intelligence Artificielle Hybride et Apprentissage Automatique

Exercice 1 - K-MEANS SUR DES POINTS EN 2D

Dans cet exercice, complétez le code Python suivant pour :

1. Créer la liste de points suivante :

$$(1,2),(2,3),(3,1),(8,8),(9,9),(8,9),(1,8),(2,9),(3,8)$$

2. Appliquer l'algorithme **K-means** avec 3 clusters
3. Visualiser les résultats sur un graphique

```python
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

# Points
points = [
    # À compléter…
]

# K-means avec 3 clusters
kmeans = # À compléter…
labels = # À compléter…

# Visualisation
plt.figure()

colors = #À compléter…

for i in range(len(points)):
    x = points[i][0]
    y = points[i][1]
    plt.scatter(x, y, color=colors[labels[i]])
    plt.text(x+0.1, y+0.1, str(points[i]))

plt.title("K-means avec 3 clusters")
plt.xlabel("x")
plt.ylabel("y")
plt.grid()
plt.show()
```

Exercice 2 - CLUSTERING DE MOTS AVEC K-MEANS

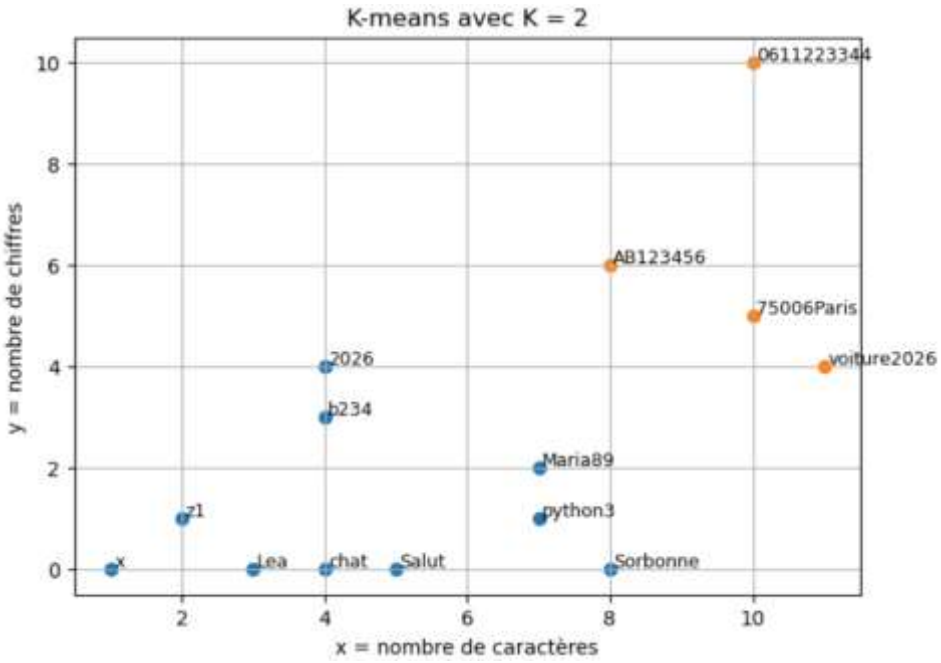
L'objectif de cet exercice est :

- Transformer des mots en points numériques (x,y)
- Appliquer l'algorithme **K-means**
- Visualiser les clusters obtenus
- Observer l'effet du choix du nombre de clusters

Étant donnée une liste de mots (certains contiennent des chiffres), complétez le code Python afin que :

1. Pour chaque mot, calcule (x,y) :
   - x = nombre total de caractères
   - y = nombre de chiffres dans le mot
2. Appliquer K-means à ces points (x,y).
3. Faire un graphique 2D : axe x = caractères, axe y = chiffres. Chaque point doit :
   - Avoir la couleur de son cluster
   - Afficher le mot à côté du point

Exécutez le code avec différentes quantités de clusters (valeurs de K différentes) et modifiez la liste de mots pour visualiser différents résultats.



Exercice 3 - K-MEANS SUR DES MOTS AVEC EMBEDDINGS

L'objectif de cet exercice est de regrouper automatiquement ces phrases en fonction de leur similarité sémantique. Vous allez :

- Transformer des phrases en vecteurs numériques (embeddings)
- Appliquer l'algorithme K-means
- Observer comment les phrases sont regroupées selon leur sens

1. **Compréhension du code** : Exécuter le code fourni pour identifier :

   - Quel modèle est utilisé pour générer les embeddings ?
   - Quelle est la dimension des vecteurs générés ?
   - Pourquoi normalise-t-on les vecteurs ?

2. **Analyse des clusters** : Après l'exécution, observez les phrases présentes dans chaque cluster.

   - Quels thèmes apparaissent clairement ?
   - Certaines phrases sont-elles mal classées ?
   - Pourquoi certaines phrases similaires apparaissent-elles dans le même cluster ?

3. **Expérimentation** : Modifiez le code et comparez les résultats avec clusters = 3 et 5

    1. Que se passe-t-il lorsque le nombre de clusters change ?
    2. Quel nombre de clusters semble le plus pertinent ?
    3. Pourquoi K-means dépend-il fortement du choix de K ?

4. **Analyse critique** : Considérez les cases suivantes :

    1. Que se passe-t-il lorsqu'une phrase est dupliquée ?
    2. Pourquoi les doublons influencent-ils le clustering ?
    3. Comment pourrait-on supprimer les doublons avant l'entraînement ?

Exercice 4 - K-MEANS AVEC WORD EMBEDDINGS + VISUALISATION (PCA)

L'objectif de cet exercice est de regrouper automatiquement ces phrases en fonction de leur similarité sémantique, puis de visualiser les clusters dans un graphique. Vous allez :

- Transformer des mini-phrases en vecteurs numériques (embeddings)
- Appliquer K-means pour regrouper les phrases selon leur sens
- Visualiser ces regroupements en 2D grâce à PCA

1. **Exécuter le code** : Lancez le programme et observez :

    - Quelle est la dimension des embeddings ?
    - Pourquoi n'affiche-t-on que les X premières valeurs des Y premières phrases ? Indiquez les valeurs dans le code pour X et Y

2. **Compréhension (PCA)** : le PCA permet de réduire la dimensionnalité des embeddings.

    - Pourquoi a-t-on besoin de PCA pour afficher les données ?
    - PCA modifie-t-il les embeddings d'origine ou seulement leur représentation ?

3. **Expérimenter** : Modifiez la quantité de clusters ainsi que les phrases pour obtenir d'autres résultats.